

第二周周报：Stage2 人脸检测、关键点、识别与部署

周期：第二周，2026-05-22 至 2026-05-28


1. 本周已完成

- 完成 Stage2 Task3.x WIDER FACE 人脸检测交付，整理 GPU Docker、数据准备、全量训练、全量评估、检测可视化和独立报告目录。
- 完成 Stage2 Task4.x 300W 人脸关键点检测与仿射对齐交付，输出 HRNet 训练/评估结果、关键点 overlay、aligned face 和 before/after grid。
- 完成 Stage2 Task5.x 第一版 **IResNet50 + ArcFace** 云端训练与 LFW 验证同步。当前展示层已统一为云端 dense 结果：**800000** 张图、**20000** 个 identities、**60** 个 epoch，best LFW accuracy **81.67%**。
- 完成 Stage2 Task6.1/6.2/6.3：模型优化方法调研、PyTorch 动态量化、ONNX 导出、ONNX Runtime 推理和 LFW protocol 对比。
- 按任务隔离原则整理交付物：Task5 展示层在 [reports/task5/](#)，Task6 代码在 [code/task6/](#)，Task6 报告在 [reports/task6/](#)，模型权重与 ONNX 文件保留在 ignored 的 [work_dirs/task6/](#)。

2. 运行截图

以下截图均为本机 PowerShell/Windows Terminal

真实运行命令后的界面；本节只放终端运行画面，不放实验结果图表。



```
insightface 1.0.1
datasets 4.8.5
easydict installed
huggingface_hub 0.36.2
hf_transfer 0.1.9
hf_xet installed
pyarrow 24.0.0
torchmetrics 1.9.0
transformers 4.37.2
webdataset 1.0.2
tensorboard 2.20.0
reportlab 4.5.1
mxnet not available (ModuleNotFoundError: No module named 'mxnet')
mmengine 0.10.7
mmdet 3.3.0
mmpose 1.3.2
cuda_available True
mps_available False
sample_image synthetic_gradient
bgr_shape (64, 64, 3)
gray_shape (64, 64)
gray_mean 89.05
stage2_config stage-2/configs/mmdet/ssd300_widerface_smoke.py
stage2_task4_config stage-2/configs/task4_mmpose/td-hm_hrnetv2-w18_300w_full_gpu.py
stage2_task5_config stage-2/configs/task5_arcface/resnet50_arcface_ms1mv3_subset_gpu.py
stage2_task5_insightface_config stage-2/configs/task5_arcface/insightface_ms1mv3_r50_full_gpu.py
stage2_task6_scripts available
unified docker environment ok
```

运行截图：GPU Docker 环境验证，显示 CUDA、MMDetection、MMPose、Task5/Task6 依赖可用。

```
Stage2 Week2 - Task5 Cl x + v
Stage2 week2 terminal run
Task: Stage2 Week2 - Task5 Cloud Summary
Working directory: C:\Users\Aaron\Documents\GitHub\CV-project

$ python - read Task5 cloud summaries
Task5 cloud result synchronized to reports/task5
num_images: 800000
num_identities: 20000
epochs_completed: 60
best_lfw_accuracy: 0.8166666666666667
lfw_eval_accuracy: 0.8166666666666667
target_met: False
training_plot: stage-2/reports/task5/assets/training/ms1mv3_dense_loss_acc_curve.png
```

运行截图：Task5 云端 800k/60 epoch/0.8167 summary 已同步到 reports/task5。

```
Stage2 Week2 - Task6 Re x + v
Stage2 week2 terminal run
Task: Stage2 Week2 - Task6 Results
Working directory: C:\Users\Aaron\Documents\GitHub\CV-project

$ python - read Task6 quantization and ONNX summaries
FP32 LFW accuracy: 0.8168333333333333
Dynamic INT8 LFW accuracy: 0.8168333333333333
FP32 model size MB: 166.58
Dynamic INT8 model size MB: 129.86
ONNX LFW accuracy: 0.8168333333333333
ONNX mean cosine: 1.0
ONNX max abs diff: 5.550682544708252e-07
```

运行截图：Task6 动态量化与 ONNX summary 检查，显示 FP32、INT8、ONNX 的 LFW 精度和模型体积。

```
Stage2 Week2 - Demo Ti x + v
Working directory: C:\Users\Aaron\Documents\GitHub\CV-project\stage-2

$ docker compose run --rm -w /workspace/stage-2 stage2-gpu python code/task5/stage2_task5_run_arcface.py train ...
Container bytedance-cv-stage2-gpu-run-aaf7fe9a570f Creating
Container bytedance-cv-stage2-gpu-run-aaf7fe9a570f Created

=====
== CUDA ==
=====

CUDA Version 11.8.0

Container image Copyright (c) 2016-2023, NVIDIA CORPORATION & AFFILIATES. All rights reserved.

This container image and its contents are governed by the NVIDIA Deep Learning Container License.
By pulling and using the container, you accept the terms and conditions of this license:
https://developer.nvidia.com/ngc/nvidia-deep-learning-container-license

A copy of this license is made available in this container at /NGC-DL-CONTAINER-LICENSE for your convenience.


epoch 1: 0%| | 0/2 [00:00<?, ?it/s]
/usr/local/lib/python3.10/dist-packages/torch/optim/lr_scheduler.py:139: UserWarning: Detected call of `lr_scheduler.step` before `optimizer.step()`. In PyTorch 1.1.0 and later, you should call them in the opposite order: `optimizer.step()` before `lr_scheduler.step()`. Failure to do this will result in PyTorch skipping the first value of the learning rate schedule. See more details at https://pytorch.org/docs/stable/optim.html#how-to-adjust-learning-rate
warnings.warn("Detected call of `lr_scheduler.step()` before `optimizer.step()`. ")
epoch 1: 100%| | 2/2 [00:00<00:00, 6.22it/s, acc=0.0000, loss=8.9759]
epoch 2: 100%| | 2/2 [00:00<00:00, 7.50it/s, acc=0.0000, loss=8.9790]
Wrote reports/task5/logs/weekly_demo_train_summary_real_terminal.json
```

运行截图：短 demo 训练命令真实启动并跑完，用于证明训练链路可运行，不作为正式指标来源。


3. 实验结果与图表

3.1 Task3 WIDER FACE 人脸检测


Task3 目标是跑通 WIDER FACE 人脸检测训练与评估链路，并把检测图、训练曲线、评估指标放入 `reports/task3/`，不与后续关键点或识别任务混在一起。



Task3 全量训练 loss 曲线。



Task3 WIDER FACE 评估指标图。




Task3 检测可视化示例。


3.2 Task4 300W 关键点检测与对齐

Task4 使用 300W + HRNetv2-W18 完成人脸 68

点关键点检测，并基于眼睛、鼻尖和嘴角估计仿射矩阵，把人脸对齐到 112x112 ArcFace 模板。



Task4 HRNet 训练 loss 曲线。



Task4 300W NME 评估指标图。




Task4 对齐 before/after 示例。


3.3 Task5 ArcFace 识别训练与 LFW 验证

Task5 展示层已同步为云端 800k dense 结果。训练曲线改为三个分面：训练 loss、训练 top-1、LFW accuracy，避免三条曲线挤在同一坐标系中。最佳 LFW 出现在 epoch 38，accuracy 为 **81.67%**；最终独立评估 summary 中 accuracy 为 **81.67%**，ROC AUC 为 **0.8791**。


LFW accuracy 从 epoch 1 就在 0.75-0.80 附近，是因为 epoch 1 已经完整看过 800k 张训练图，LFW 又是 aligned 1:1 verification protocol，并且每折会在训练折上选择阈值；这会让早期 embedding 已能在相对容易的 LFW 上得到中等准确率。后续 accuracy 波动和停滞，说明第一版自实现模型逐渐把 closed-set 分类身份拟合得更好，但 open-set embedding 泛化没有继续提升，所以不是单纯“epoch 太少”或“学习率太低”能解释。



Task5 云端训练曲线，分面展示 train loss、train top-1 与 LFW accuracy。



Task5 LFW ROC 曲线。




Task5 LFW 相似度分布。

3.4 Task6 模型压缩与 ONNX 推理


模型	LFW accuracy	latency ms/image	model size MB
---	---	---	---
FP32	81.68%	62.408	166.58
Dynamic INT8	81.68%	62.935	129.86
ONNX Runtime	81.68%	44.860	166.32

Task6 Dynamic Quantization Comparison



Task6 动态量化对比图。

Task6 ONNX Runtime Comparison



Task6 ONNX 推理对比图。

4. 关键代码段与解释

4.1 Task3 WIDER FACE 数据与检测链路

文件：[code/prepare/stage2_task3_2_prepare_widerface.py](#)、[code/evaluate/stage2_task3_3_evaluate_widerface.py](#)

```
writer.writerow(["image_path", "x1", "y1", "w", "h", "blur", "expression", "illumination",  
"invalid", "occlusion", "pose"])  
detections = nms_detections(detections, iou_thr=args.iou_thr)  
draw_detections(image, detections[: args.vis_top_k], out_path)
```

解释：Task3 将 WIDER FACE 标注转换为训练可读的结构化索引，评估阶段再按 score threshold 和 IoU NMS 得到检测框，并输出固定数量的可视化样例，保证训练、评估和报告图可以追溯。

4.2 Task4 关键点驱动的人脸对齐

文件：[code/task4/stage2_task4_3_align_faces.py](#)

```
src = np.float32([left_eye, right_eye, nose_tip, left_mouth, right_mouth])  
dst = np.float32(ARCFACE_TEMPLATE_112)  
matrix, inliers = cv2.estimateAffinePartial2D(src, dst, method=cv2.LMEDS)  
aligned = cv2.warpAffine(image, matrix, (112, 112), flags=cv2.INTER_LINEAR)
```

解释：Task4 不只画关键点，还把左眼、右眼、鼻尖和嘴角映射到 ArcFace 112x112 模板。这样输出的 aligned face 可以直接服务后续人脸识别模型输入。

4.3 Task5 ArcFace margin 与 LFW 10-fold 验证

文件：[code/task5/stage2_task5_run_arcface.py](#)

```
cosine = F.linear(F.normalize(embeddings), F.normalize(self.weight))  
theta = torch.acos(cosine.clamp(-1.0 + 1e-7, 1.0 - 1e-7))  
target_logits = torch.cos(theta + self.margin)  
logits = cosine.scatter(1, labels.view(-1, 1), target_logits.gather(1, labels.view(-1, 1))) *  
self.scale
```

解释：ArcFace 在目标类别角度上加入 margin，使同一身份的 embedding 更紧、不同身份之间角度间隔更大。LFW 评估则使用 6000 pairs 的 10-fold protocol，每一折只在训练折选阈值，再在测试折计算 accuracy。

4.4 Task6 动态量化与 ONNX 导出

文件：[code/task6/stage2_task6_2_quantize_arcface.py](#)、[code/task6/stage2_task6_3_export_onnx.py](#)

```
quantized = torch.quantization.quantize_dynamic(  
    fp32_backbone.cpu(), {torch.nn.Linear}, dtype=torch.qint8  
)  
torch.onnx.export(  
    backbone, dummy, onnx_out,  
    input_names=["input"], output_names=["embedding"],  
    dynamic_axes={"input": {0: "batch"}, "embedding": {0: "batch"}},  
)
```


解释：动态量化只压缩 **Linear** 层，因此对 IResNet50 这种卷积为主的模型提升有限；ONNX 导出保留动态 batch 维度，并用同一 LFW protocol 验证 embedding 数值一致性和推理指标。

5. 下周待办

- 如果继续追求 Task5 的 98.5% LFW 目标，优先采用官方 InsightFace full MS1MV3 RecordIO 训练路线，而不是继续扩大第一版自实现训练。
- 在 Task6 基础上尝试静态量化、结构化剪枝或 TensorRT/ONNX Runtime GPU provider，预期比仅动态量化 **Linear** 层更有部署收益。
- 整理最终提交目录，确认 **data/**、**work_dirs/**、**.pth**、**.onnx**、云端 tar 包继续被 Git 忽略，只提交代码、报告、summary、PDF 和小体积图表。