


第二周周报：阶段二人脸识别训练、压缩与部署

周期：第二周，2026-05-22 至 2026-05-28


1. 本周已完成

- 完成 Stage2 Task3.x WIDER FACE 人脸检测训练链路整理，并将检测任务报告、训练曲线、检测可视化保留在 Task3 独立目录。
- 完成 Stage2 Task4.x 300W 人脸关键点检测与仿射对齐交付，输出关键点 overlay、对齐图和任务报告。
- 完成 Stage2 Task5.x 第一版 **IResNet50 + ArcFace** 训练和 LFW 评估。云端第一版 checkpoint 的 LFW accuracy 为 **81.67%**，作为 Task6 模型压缩基线。
- 完成 Stage2 Task6.1/6.2/6.3：模型优化技术调研、PyTorch 动态量化、ONNX 导出与 ONNX Runtime 推理验证。
- 按任务隔离原则整理交付物：Task6 代码在 [code/task6/](#)，报告在 [reports/task6/](#)，模型和 ONNX artifact 在 ignored 的 [work_dirs/task6/](#)。

2. 运行截图




Task5 云端训练曲线




Task5 云端 LFW ROC

Task6 Dynamic Quantization Comparison



Task6 动态量化对比

Task6 ONNX Runtime Comparison



Task6 ONNX 推理对比

3. 实验结果与图表

3.1 Task5 第一版 ArcFace 基线

Task6 使用的源模型来自 [reports/task5/task5_cloud_results_8167.tar.gz](#)，训练集为 dense MS1MV3 子集，云端训练记录显示最终使用 800000 张图片、20000 个 identities、60 个 epoch。

3.2 动态量化结果

模型	LFW accuracy	latency ms/image	model size MB
FP32	81.68%	62.408	166.58
Dynamic INT8	81.68%	62.935	129.86

3.3 ONNX 推理结果

模型	LFW accuracy	latency ms/image	model size MB
ONNX Runtime	81.68%	44.860	166.32

ONNX 与 PyTorch embedding 对比：mean cosine 1.000000，max abs diff 0.000001。

4. 关键代码段与解释

4.1 Task6 源模型隔离

文件：[code/task6/stage2_task6_prepare_source_model.py](#)

```
extract_member(tar, TASK5_BEST, best_out)
extract_member(tar, TASK5_LFW_SUMMARY, lfw_summary_out)
extract_member(tar, TASK5_TRAIN_SUMMARY, train_summary_out)
```

解释：Task6 不直接覆盖 Task5 的 `work_dirs/`，而是从云端 tar 包中只提取第一版 `best.pth` 和 summary 到 Task6 专用目录，保证后续量化和 ONNX 实验不会误用本地旧 checkpoint。

4.2 动态量化

文件：[code/task6/stage2_task6_2_quantize_arcface.py](#)

```
quantized = torch.quantization.quantize_dynamic(
    fp32_backbone.cpu(), {torch.nn.Linear}, dtype=torch.qint8
)
```

解释：PyTorch 动态量化仅量化 `Linear` 层，适合快速得到 CPU 推理 baseline。由于 IResNet50 以卷积为主，报告中同时记录精度、速度和模型体积，避免只看单一指标。

4.3 ONNX 导出

文件：[code/task6/stage2_task6_3_export_onnx.py](#)

```
torch.onnx.export(  
    backbone,  
    dummy,  
    onnx_out,  
    input_names=["input"],  
    output_names=["embedding"],  
    dynamic_axes={"input": {0: "batch"}, "embedding": {0: "batch"}},  
)
```

解释：导出的 ONNX 模型保留动态 batch 维度，便于在 ONNX Runtime 中按不同 batch size 做推理。输出 embedding 继续使用 LFW 6000-pair 10-fold protocol 评估。

5. 下周待办

- 若需要继续提升 Task5 精度，优先切换到官方 InsightFace full MS1MV3 RecordIO 路线，而不是继续扩大第一版自实现训练。
- 在 Task6 基础上尝试静态量化、结构化剪枝或 TensorRT/ONNX Runtime GPU provider，加速效果会比仅动态量化 **Linear** 层更明显。
- 整理最终提交目录，确认 **data/**、**work_dirs/**、**.pth**、**.onnx** 继续被 Git 忽略，只提交代码、报告、summary、PDF 和小体积图表。